RESUMEN DE PAPER · GENERACIÓN PERSONALIZADA DE NIVELES

Hacia la generación automática de contenido personalizado para juegos de plataformas

Towards Automatic Personalized Content Generation for Platform Games

Autores	Noor Shaker, Georgios N. Yannakakis y Julian Togelius (Center for Computer Games Research, IT University of Copenhagen)

Publicación	Proceedings of the Sixth AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE 2010), 6(1), 63–68
Cita APA	Shaker, N., Yannakakis, G. N., & Togelius, J. (2010). Towards automatic personalized content generation for platform games. *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment, 6*(1), 63–68. https://doi.org/10.1609/aiide.v6i1.12399
Técnica central	Modelos de experiencia del jugador (perceptrones aprendidos por preferencias) + búsqueda exhaustiva de los parámetros del nivel que maximizan la diversión predicha

Resumen

El paper muestra que es posible **generar automáticamente niveles personalizados** para juegos de plataformas. Se basa en un trabajo previo que construyó modelos capaces de predecir la experiencia del jugador a partir de características del diseño del nivel y del estilo de juego; esos modelos se obtienen con **aprendizaje de preferencias**, usando cuestionarios que los jugadores responden después de jugar distintos niveles.

Contribuciones

- Modelos **más precisos** construidos con un conjunto de datos mucho más grande.
- Un **mecanismo para adaptar** los parámetros de diseño del nivel a un jugador y estilo de juego dados.
- La **evaluación** de ese mecanismo con jugadores algorítmicos (agentes de IA) y humanos.
- Resultado: el mecanismo optimiza eficazmente los parámetros del nivel para jugadores concretos.

1. Introducción

La PCG es importante tanto **fuera de línea** (hacer más eficiente el desarrollo, ya que el contenido consume buena parte del presupuesto) como **en línea** (aumentar la rejugabilidad, adaptar el juego a distintos públicos y crear nuevos tipos de juego basados en contenido adaptado al jugador). La literatura sobre PCG personalizada es escasa porque es una dirección de investigación nueva.

Las emociones y la experiencia del jugador son críticas: puede frustrarse si no avanza, sentirse satisfecho al superar un nivel o abandonar ante un problema que parece imposible. Existen muchas teorías sobre qué hace divertido un juego, pero son **cualitativas** y generales; para diseñar o adaptar juegos automáticamente se necesita investigación empírica sobre juegos concretos.

La optimización basada en modelos empíricos se ha centrado sobre todo en el comportamiento de personajes no jugables y en el **balance dinámico de dificultad**, con métodos a menudo limitados a ciertos géneros. En PCG, los intentos publicados de generar segmentos coherentes como niveles son escasos, y en plataformas solo hay unos pocos (Compton y Mateas, 2006; Smith et al., 2009). La PCG

adaptativa se ha probado en pistas de carreras, armas y reglas de juegos de mesa.

La contribución principal es un **mecanismo de adaptación en línea que maximiza la diversión** del jugador en juegos de plataformas, extendiendo el trabajo de Pedersen, Togelius y Yannakakis (2010) con: (1) un modelo reconstruido con más datos; (2) un mecanismo de adaptación en línea basado en esos modelos; y (3) pruebas con humanos y con controladores de la **Mario AI Competition 2009**.

2. Juego de prueba

Se usa una versión modificada de **Infinite Mario Bros** de Markus Persson, un clon de dominio público de Super Mario Bros. Mario camina, corre, se agacha, salta y lanza bolas de fuego; el objetivo es llegar al final del nivel, y los objetivos secundarios son juntar monedas y terminar rápido. Su característica distintiva es la **generación automática de niveles**: cada partida recorre un ancho fijo y agrega elementos según heurísticas definidas por **parámetros de colocación**. Los autores se concentran en unos pocos parámetros que afectan la experiencia.



Figura 1. Captura de Infinite Mario Bros.

3. Recolección de datos

Se recolectaron tres tipos de datos de **327 jugadores**:

- **Características controlables:** parámetros usados para generar el nivel, que afectan su tipo y dificultad. Tres se relacionan con **huecos** (número de huecos, ancho promedio, entropía de su ubicación) y una con el **cambio de dirección** (porcentaje del nivel jugado hacia la izquierda).
- **Características de juego:** estadísticas de cómo juega el usuario (cuántas veces saltó, corrió o murió, cuánto se movió a la izquierda, cuántos enemigos mató). **No se controlan**, porque dependen de la habilidad y el estilo del jugador.
- **Experiencia del jugador:** tras jugar cuatro partidas, en dos pares jugados en ambos órdenes, cada jugador indicó cuál prefería en tres dimensiones emocionales (**diversión, desafío y frustración**) con un cuestionario de elección forzada de 4 alternativas.

El análisis usa **654 pares de partidas** (1308 sesiones), más del doble que el trabajo previo. Tras eliminar los pares sin preferencia clara quedan **458** (diversión), **463** (desafío) y **463** (frustración).

4. Modelado de las preferencias de experiencia

Primero se usan **perceptrones de una capa** (SLP) con selección de características para aproximar el estado afectivo; luego se **evolucionan** la topología y los pesos de **perceptrones multicapa** (MLP) para ajustarse a las preferencias reportadas.

Modelos SLP: selección de características

Durante el juego se extrajeron **58 características** (tiempo, acciones, causas de muerte, etc.). Para que el modelo sea fácil de analizar, útil para adaptación en línea y barato de calcular, se usa **selección secuencial hacia adelante** (SFS) para encontrar el subconjunto mínimo con mayor precisión, medida como la precisión promedio del SLP en tres corridas con validación cruzada de 3 particiones. Los subconjuntos elegidos (+/− indica correlación positiva o negativa) son:

- **Diversión (4):** tiempo para completar el nivel (+), tiempo en modo grande (+), tiempo corriendo (+) y caparazones lanzados (+).
- **Frustración (7):** tiempo para completar (+), cañones disparados (+), bloques de poder destruidos (+), cambios de modo (+), **ancho promedio de huecos** (+), bloques de monedas destruidos (+) y número de saltos (−).
- **Desafío (6):** monedas recogidas (+), tiempo para completar (−), **ancho promedio de huecos** (+), disparos (+), cañones en el nivel (+) y muertes por cañón (+).

Con SLP se predicen diversión, frustración y desafío con **64 %**, **84,66 %** y **70 %** de precisión.

Modelos MLP

Como el objetivo es generar contenido adaptado en tiempo real, hay que poder predecir las emociones al menos en parte a partir de las **características controlables**. Por eso todas las controlables que no estaban ya seleccionadas se **fuerzan** como entradas del MLP, y se optimiza la topología.

Tabla 1. Desempeño de los MLP del modelo anterior y del actual.

	Diversión	Frustración	Desafío
Topología del MLP	7-10-1	10-4-2-1	9-3-1
MLP anterior	74,21 %	91,33 %	79,37 %
MLP actual	69,66 %	89,33 %	74,66 %

Con el conjunto de datos más grande, la precisión baja levemente (unos 5 puntos en diversión y desafío), pero los autores la consideran aceptable y con buena generalización. La frustración es la mejor predicha (89,33 %). Las redes varían en tamaño: la de desafío es la más pequeña (una capa oculta de 3 neuronas), la de frustración tiene dos capas ocultas y la de diversión una capa de 10 neuronas.

5. Mecanismo de adaptación en línea

El objetivo es adaptar dinámicamente los parámetros de generación según los modelos de experiencia. El enfoque realiza una **búsqueda exhaustiva** en el espacio de características controlables para encontrar la combinación que, junto con las características de juego observadas, **maximiza la salida del MLP**.

Tabla A. Espacio de búsqueda de las características controlables (elaboración del resumen a partir del texto).

Característica controlable	Rango	Paso	Valores
Número de huecos	[4, 10]	1	7
Ancho promedio de huecos	[10, 30]	1	21
Ubicación de huecos (entropía)	[0, 1]	0,1	11
Cambios de dirección	[0, 1]	0,1	11

La búsqueda parte de los valores mínimos y aumenta cada característica según su paso; cada configuración se evalúa en el MLP junto con las características de juego recientes, y la que maximiza la salida genera el siguiente nivel. Los autores reportan un espacio de unas **12 000 configuraciones**, lo bastante pequeño para encontrar el óptimo casi al instante y generar niveles en tiempo real.

Nota del resumen: con los rangos y pasos indicados, el espacio tiene 7 × 21 × 11 × 11 = **17 787** configuraciones, no 12 000; la cifra del paper no coincide con sus propios rangos.

6. Prueba de la adaptación en línea

El mecanismo genera casi al instante un nivel que optimiza la experiencia predicha a partir del estilo de juego del nivel anterior. Pero como el estilo del jugador cambia con el nivel, el efecto de las características controlables es indirecto, y hay que estudiar el mecanismo a lo largo del tiempo. Se usan jugadores humanos y **agentes de IA**, porque los agentes se comportan de forma consistente y tienen más tiempo. Se usaron dos controladores de la Mario AI Competition 2009:

- **Agente de Robin Baumgarten** (ganador): búsqueda A* en el espacio de estados que simula su trayectoria y la de los enemigos. Avanza muy rápido, saltando y disparando casi sin parar.
- **Agente de Sergio López:** heurística simple que decide cuándo y cuán alto saltar. Juega a un ritmo más pausado, salta solo cuando es necesario y nunca dispara; se parece más a un humano.

7. Experimento 1: optimizar la experiencia para un estilo de juego fijo

Pasos: (1) se genera un nivel inicial con parámetros aleatorios; (2) un agente lo juega mientras se registran las características de juego; (3) con ellas se eligen los valores controlables que optimizan la experiencia; (4) se genera un nuevo nivel adaptado. Cada agente jugó **50 niveles** (el primero aleatorio y el resto adaptados), y el experimento se repitió **10 veces** por agente. Como comparación se generaron 50 niveles con parámetros aleatorios.

El mecanismo genera niveles con **mayor diversión predicha** que los aleatorios. Para el agente de Sergio se alcanzó en promedio **81,31 %** de diversión, y para el de Robin **68,71 %**. Los autores atribuyen la diferencia al estilo: el modelo se entrenó con datos humanos y el agente de Sergio juega de forma más humana. Aclaran que «diversión» siempre se refiere a la diversión **predicha**; no afirman que los algoritmos se divirtieran.

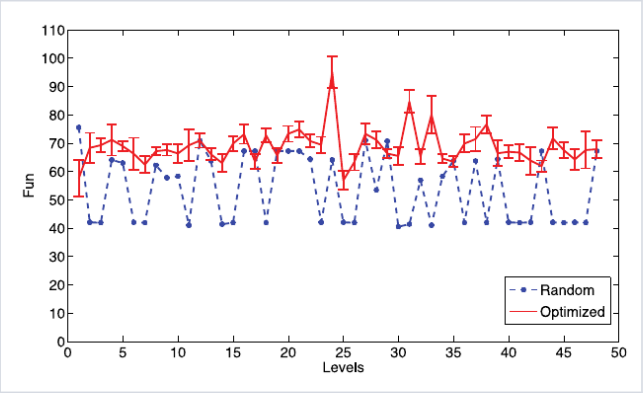


Figura 2. Niveles optimizados para diversión vs. niveles aleatorios, agente de Robin.

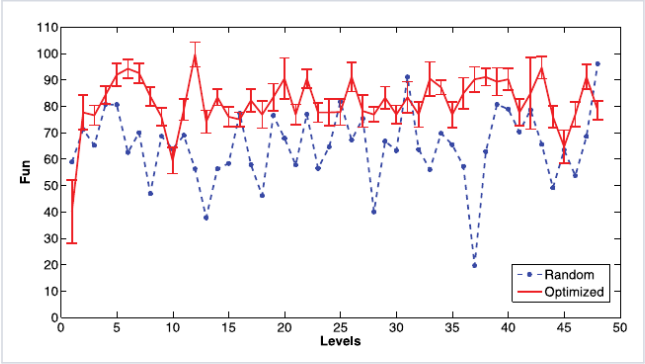


Figura 3. Niveles optimizados para diversión vs. niveles aleatorios, agente de Sergio.

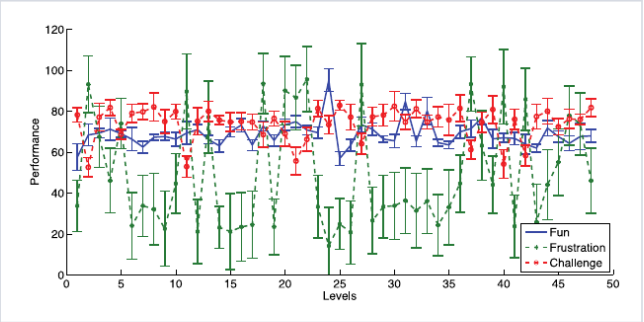


Figura 4. Niveles optimizados para diversión, agente de Robin (diversión, frustración y desafío).

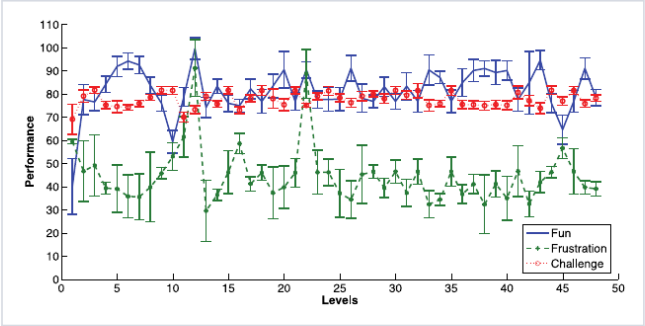


Figura 5. Niveles optimizados para diversión, agente de Sergio (diversión, frustración y desafío).

Análisis estadístico

Para ver si optimizar una emoción afecta a las otras, se optimizó la diversión mientras se monitoreaban la frustración y el desafío. Para el agente de Robin hay una correlación significativa entre desafío y frustración ($p = 3{,}57 \times 10^{-20}$), y es **negativa (−0,66)**: para jugadores como él, los niveles desafiantes se predicen menos frustrantes. Para el agente de Sergio no hay correlaciones significativas, lo que muestra la sensibilidad del modelo al tipo de jugador. En ambos agentes, los niveles optimizados para diversión indujeron **alto desafío**.

8. Experimento 2: adaptación dinámica a estilos de juego cambiantes

Para probar la generalización, los dos agentes jugaron por turnos **100 niveles**, cambiando de agente cada 20. La diversión ronda el **70 %** con el agente de Robin y sube a cerca del **80 %** con el de Sergio, para volver a bajar al cambiar de nuevo: el modelo se adapta al tipo de jugador (Figura 6).

Con **cuatro jugadores humanos** (12 niveles cada uno, 48 en total) los resultados fueron similares, con diversión promedio de **80,65 %, 93,88 %, 82,11 % y 85,49 %** (Figura 7). Además, esos participantes y otros 6 compararon un nivel aleatorio con el primer nivel adaptado: el **60 %** prefirió el adaptado.

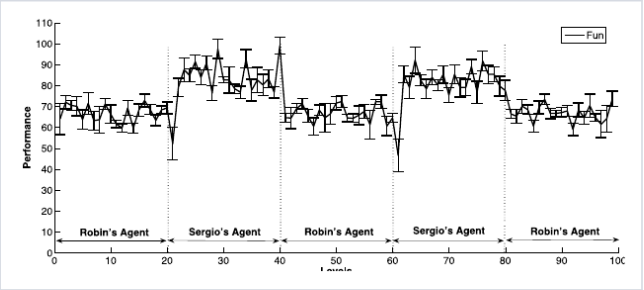


Figura 6. Diversión optimizada para los dos agentes alternados cada 20 niveles.

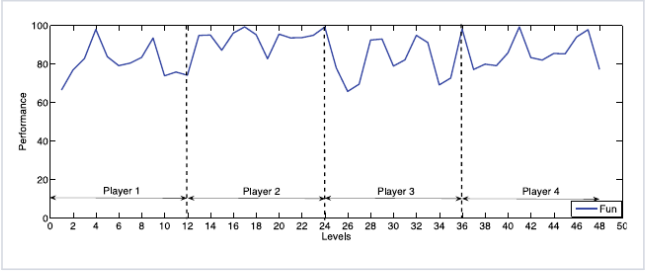


Figura 7. Diversión optimizada para cuatro jugadores humanos.

9. Discusión

- Solo se definieron **cuatro características controlables**, tres de ellas sobre huecos; en el futuro se quieren investigar muchas más.
- Los resultados son **sugerentes**, pues se basan en dos agentes y cuatro humanos; se necesita más evaluación.
- Los autores creen que el enfoque **generaliza** a otros juegos de acción en primera o tercera persona, porque conceptos como velocidad de avance, disparos o entropía de colocación de objetos tienen análogos claros.
- Limitación: depende de cuestionarios **posteriores** a la experiencia, que solo dan datos cuando se pregunta y pueden ser intrusivos. Proponen ventanas de tiempo, redes recurrentes y medidas fisiológicas.
- El contenido se genera al final de cada nivel; el paso siguiente es usar **ventanas de tiempo más cortas** para una adaptación más fina.

10. Conclusión

El trabajo presenta un mecanismo de adaptación en línea que optimiza eficazmente la experiencia del jugador y permite generar niveles a la medida de jugadores concretos. Los predictores alcanzan una precisión aceptable y el mecanismo muestra resultados prometedores, aunque quedan muchas ideas por mejorar.

Utilidad para tu modelo matemático

Es el ejemplo más claro, entre tus referencias, de un problema de **optimización** con función objetivo explícita:

- **Variables de decisión:** c = (huecos, ancho promedio, entropía de huecos, cambios de dirección).
- **Dominios:** {4,...,10} × {10,...,30} × {0; 0,1; ...; 1} × {0; 0,1; ...; 1}, un espacio discreto pequeño que se recorre completo.
- **Parámetros:** las características de juego g observadas en el nivel anterior y los pesos del MLP entrenado.
- **Función objetivo:** maximizar $f_{MLP}(c, g)$, la diversión predicha.
- **Restricciones:** solo las cotas de los dominios; la jugabilidad no se modela explícitamente (depende del generador de Infinite Mario).
- **Variante del problema:** generación **personalizada / adaptativa en línea**.