RESUMEN DE PAPER · ESTADO DEL ARTE (SURVEY)

Generación procedural de contenido en juegos: una revisión con perspectivas sobre la integración de LLM

Procedural Content Generation in Games: A Survey with Insights on Emerging LLM Integration

Autores	Mahdi Farrokhi Maleki y Richard Zhao (Departamento de Ciencias de la Computación, University of Calgary, Canadá)

Publicación	Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE), 20(1), 167–178, 2024 · preprint arXiv:2410.15644
Cita APA	Maleki, M. F., & Zhao, R. (2024). Procedural content generation in games: A survey with insights on emerging LLM integration. *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment, 20*(1), 167–178. https://doi.org/10.1609/aiide.v20i1.31877
Tipo de trabajo	Revisión bibliográfica (survey) de 207 artículos publicados entre 2019 y 2023

Resumen

La generación procedural de contenido (PCG) es la creación automática de contenido de juegos mediante algoritmos. Tiene una larga historia tanto en la industria como en la academia: aumenta el compromiso del jugador y facilita el trabajo de los diseñadores. Aunque los avances en aprendizaje profundo permitieron contenido más sofisticado, los autores sostienen que fue la llegada de los **modelos grandes de lenguaje (LLM)** lo que realmente cambió la trayectoria del área.

El survey compara los algoritmos usados en PCG, agrupados en **métodos basados en búsqueda**, **métodos de aprendizaje automático**, **otros métodos** frecuentes (p. ej. funciones de ruido) y los recién llegados **LLM**, y dedica una discusión a los **métodos combinados**. Además, compara los métodos según el tipo de contenido que generan y la fecha de publicación, identifica vacíos en la investigación y propone direcciones futuras.

Contribuciones según los autores

- Revisión integral tanto de los **métodos** como del **contenido** generado.
- Primera revisión (al momento de escribirse) que incluye a los **LLM** como método de PCG y explica por qué son distintos de los enfoques anteriores.
- Una categoría nueva de **métodos combinados**, que consideran clave para el futuro del área.
- Una **línea de tiempo** de los métodos usados en los últimos 5 años, que revela la tendencia actual.

Introducción

La industria del videojuego superó en 2022 los ingresos combinados de la música y el cine, por lo que siempre necesita contenido nuevo; sin embargo, crear un juego puede tomar años. La PCG se plantea como una solución: aumenta el valor de rejugabilidad, reduce costos de producción y minimiza el esfuerzo. Existe desde los años 80, principalmente en *roguelikes* como *Beneath Apple Manor* (1978) y *Rogue* (1980), que da nombre al género.

La PCG se usa para generar recursos artísticos, **mapas y niveles**, mecánicas de juego y música. Los algoritmos varían mucho según el contenido, pero la mayoría cae en tres categorías: (1) **basados en búsqueda** (p. ej. MCTS), centrados en optimización; (2) **basados en aprendizaje**, incluido el aprendizaje profundo (GAN, aprendizaje por refuerzo); y (3) **otros**, como funciones de ruido y gramáticas generativas. A ellos se suma el actor más nuevo: los LLM.

Trabajos relacionados

Existen surveys previos con distintos focos: detalles técnicos de los algoritmos (Zhang et al., 2022), el contenido generado (Hendrikx et al., 2013; De Carli et al., 2011), aprendizaje automático y profundo en PCG (Summerville et al., 2018), o generación de puzles (Liu et al., 2021). También hay dos libros de referencia: uno de PCG (Shaker, Togelius y Nelson, 2016) y uno de IA para juegos (Yannakakis y Togelius, 2018), que cubren métodos de búsqueda, basados en *solvers*, constructivos (autómatas celulares, gramáticas), fractales, ruido y métodos ad hoc. El survey más reciente (2022) no analiza el contenido en detalle ni identifica vacíos, y desde entonces el área creció rápidamente, sobre todo con aprendizaje profundo y LLM.

Estructura de la revisión

Primero se presentan los tipos de contenido; luego, cada categoría de algoritmos; después, el análisis de tendencias, vacíos y direcciones futuras; y finalmente una conclusión. Los **criterios de inclusión** fueron:

- Artículos de PCG para juegos publicados entre **2019 y 2023** en cinco series de conferencias: **FDG (40 %)**, **CoG (33 %)**, **AIIDE (24 %)**, CHI PLAY (2 %) y ACG (1 %): en total **207 artículos**. Los trabajos anteriores solo se discuten si son influyentes o muy citados (búsqueda en Google Scholar con *('Procedural Content Generation' OR PCG) AND (game OR games)*).
- Solo trabajos que **generan** contenido: quedan fuera los que solo lo **evalúan** (p. ej. Osborn et al., 2019).
- Se excluyen los trabajos centrados únicamente en el comportamiento de personajes no jugables (NPC).
- Se mencionan también juegos de mesa, aunque el foco son los videojuegos.
- Solo contenido para juegos (no películas, arte ni entornos de prueba para IA).

Novedad del trabajo

Se diferencia de los surveys previos por: (i) revisar a la vez métodos y contenido; (ii) ser la primera revisión en incluir los LLM; (iii) añadir la categoría de métodos combinados; y (iv) construir una línea de tiempo de los métodos a partir de cinco años de publicaciones.

Tipos de contenido

Casi todo puede generarse hoy, pero el contenido varía según el algoritmo: los LLM se usan sobre todo para narrativa, y las GAN se consideran mejores para imágenes y **niveles 2D**. El contenido puede clasificarse como generado **en línea** (durante la ejecución del juego) o **fuera de línea** (durante el desarrollo), y como necesario u opcional. Los autores adaptan la clasificación de Hendrikx et al. (2013) en cinco categorías:

Tabla A. Categorías de contenido usadas en el survey (elaboración del resumen a partir del texto).

Categoría	Qué incluye
1. Piezas de juego (*game bits*)	Las unidades más pequeñas: texturas, sonidos, vegetación, estructuras y edificios, propiedades de objetos, arte e imágenes.
2. Espacio de juego	El entorno físico donde ocurre el juego, construido con piezas: mapas, caminos e incluso mundos completos.
3. Escenarios de juego	Partes ligadas a la narrativa: conversaciones, historias, misiones, puzles y **elementos interactivos de nivel**. Aquí ubican los **niveles de juegos 2D de desplazamiento lateral** y los niveles de juegos musicales (Guitar Hero, DDR).
4. Diseño de juego	Mecánicas y reglas (qué puede hacer el jugador y cuáles son los objetivos) y sistemas, p. ej. puntos de aparición en juegos de disparos.
5. Contenido derivado	Lo no esencial que ayuda a la inmersión: interacciones de NPC de fondo, noticias dentro del juego, charla de personajes.

Algoritmos de PCG

Los métodos se agrupan en cinco categorías: **basados en búsqueda**, **basados en aprendizaje automático**, **otros**, **LLM** y **combinados** (trabajos que usan varios métodos, en paralelo o integrados).

Métodos basados en búsqueda

El término *search-based PCG* fue acuñado por Togelius et al. (2010). Es un caso especial de **generar y probar**: el contenido no se entrega directamente, sino que primero se evalúa con una función de prueba. Se distingue por dos criterios: (1) la prueba asigna un **valor real** (la **aptitud** o *fitness*) en lugar de solo aceptar o rechazar; y (2) el contenido nuevo se crea **modificando** el contenido anterior. Se ha usado para puzles, pistas de carreras, niveles, terrenos y mapas. Aunque lo más común son los algoritmos evolutivos, no es obligatorio usarlos.

- **Algoritmos evolutivos:** una población de candidatos se evalúa y ordena en cada generación; los peores se reemplazan por copias mutadas o recombinadas de los mejores. Los algoritmos genéticos se usan para crear **niveles jugables** y piezas de juego, crucigramas, bandas sonoras, mapas, caminos y niveles de juegos de mesa.
- **Algoritmos de planificación:** a partir de un estado inicial, una meta y un dominio de acciones, producen una secuencia de acciones que cumple la meta. Se usan sobre todo para generar **historias** lógicamente coherentes.
- **Wave Function Collapse (WFC):** algoritmo de síntesis de texturas que **garantiza** que la salida solo contiene patrones de N×N presentes en la entrada; por eso es ideal para generar niveles y pixel art. Admite restricciones, lo que facilita combinarlo con otros métodos o con diseño manual.
- **Monte Carlo Tree Search (MCTS):** búsqueda heurística en espacios combinatorios representados como árboles (nodos = estados, aristas = acciones).
- **Recocido simulado:** se modifica al azar una configuración y se compara con la anterior mediante una función de costo; si es peor, se acepta con cierta probabilidad.
- **Optimización por enjambre de partículas (PSO):** inspirada en bandadas y cardúmenes; cada individuo aprovecha los descubrimientos del resto para buscar el óptimo.

Métodos basados en aprendizaje automático

Ganaron popularidad en la última década gracias al aprendizaje profundo. Además de generar contenido, se usan mucho para **probar** mapas generados por otros algoritmos. No todos los trabajos usan redes complejas.

- **Redes neuronales simples:** p. ej. convertir imágenes en niveles (Chen et al., 2020).
- **RNN y LSTM:** para datos secuenciales. Summerville y Mateas (2016) tratan los **niveles de Mario como una secuencia** y combinan cadenas de Markov con LSTM.
- **GAN:** un generador y un discriminador entrenados en competencia; ideales para contenido representado como imágenes o **matrices 2D de tiles** (niveles, mapas, sprites). Observación importante de los autores: en los trabajos con GAN para niveles, estos se tratan **solo como imágenes** y **no se consideran las restricciones de validez**.
- **Modelos de Markov:** método constructivo que genera según la probabilidad del siguiente estado dado el actual (n-gramas). Las cadenas de Markov multidimensionales consideran un vecindario; Snodgrass y Ontañón desarrollaron un campo aleatorio de Markov que funcionó mejor en *Kid Icarus*, donde la ubicación de plataformas es clave para la jugabilidad.
- **Autoencoders y VAE:** comprimen y reconstruyen datos; se usan para generar y **mezclar** niveles de varios juegos de plataformas, y para **reparar** niveles injugables.
- **Aprendizaje por refuerzo:** la mayoría de los trabajos lo usa para crear **agentes que juegan** los niveles y así evaluarlos indirectamente. Para generar, el problema se formula como un proceso de decisión de Markov, lo que no es trivial.
- **Transformers:** basados en autoatención; p. ej. PCGPT genera mapas de Sokoban.

Otros métodos

- **Generadores pseudoaleatorios (PRNG) y ruido:** uno de los enfoques más antiguos (semilla + fórmula + distribución). El ruido de Perlin es común para texturas. Su principal desventaja es que el resultado **carece de estructura significativa**.
- **Gramáticas generativas:** provienen de Chomsky (años 60); reglas que reemplazan símbolos por otros (L-systems, gramáticas de forma). Se usan para plantas, mazmorras lineales y misiones. Su limitación: son **lineales**.
- **Grafos generativos:** las gramáticas de grafos resuelven la linealidad. Antes requerían un experto para diseñar las reglas; hoy hay trabajos que las crean automáticamente. Ejemplo industrial: SpeedTree.
- **Fractales:** autosimilitud para imitar procesos naturales (erosión, crecimiento de plantas) y generar terreno con niveles de detalle.
- **Casos innovadores:** generación de mapas con computación cuántica (Wootton, 2020).

Modelos grandes de lenguaje (LLM)

Encontraron **17 artículos** que usan LLM (más 3 que los combinan con otros métodos); **13** de ellos (más 2 combinados) son de **2023**, coincidiendo con el lanzamiento de ChatGPT. Se usan para narrativas, charla de NPC e incluso mecánicas: *AI Dungeon 2* (GPT-2), *1001 Nights*, asistentes para directores de juegos de rol, SCENECRAFT (escenas a partir de instrucciones en lenguaje natural) y generación de niveles (Todd et al., 2023; Nasir y Togelius, 2023; **MarioGPT**, un GPT-2 ajustado para generar niveles de Super Mario Bros a partir de texto). Los autores destacan el modelo **como servicio** (MaaS): los modelos comerciales son cajas negras, y la investigación pasó de entrenar modelos a aprender a usar modelos existentes.

Métodos combinados

El ejemplo más popular es la **evolución de variables latentes**: combinar aprendizaje no supervisado (GAN o VAE) con computación evolutiva para buscar contenido en el espacio aprendido; se ha aplicado a niveles de **Super Mario Bros** y Zelda (Volz et al., 2018; Schrum et al., 2020). El aprendizaje por refuerzo también se combina con otros métodos (p. ej. evaluar niveles generados con lenguaje natural), y el RL y la búsqueda son eficaces para **reparar** contenido generado por GAN o LSTM. Empiezan a aparecer combinaciones con LLM (LLM + RL; LLM + algoritmo genético).

Análisis

Tendencias

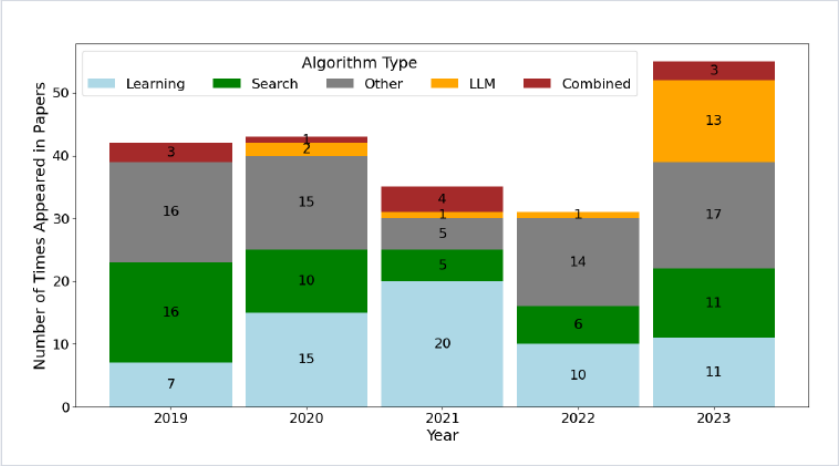


Figura 1. Línea de tiempo de los tipos de algoritmo que aparecen en los artículos de PCG de los últimos cinco años (aprendizaje, búsqueda, otros, LLM y combinados).

La Figura 2 resume los 207 artículos por tipo de contenido y año, y la Figura 3 muestra los **629 autores** involucrados. Las conclusiones principales son:

- **La generación de niveles es, por lejos, el tema más investigado: 102 artículos**, casi la mitad. Salvo excepciones, se centran en **niveles 2D**, lo que los autores consideran razonable porque un nivel 3D es mucho más complejo.
- **Los plataformas 2D son un género popular** en PCG, y **Super Mario Bros.** es el entorno más usado (**18 artículos**).
- El interés por el **aprendizaje automático** sigue creciendo y no se ha desacelerado.
- Solo cinco artículos anteriores a 2023 usaban LLM, todos con modelos abiertos (GPT-2, BERT). En 2023 explotó su uso y se pasó a servicios cerrados basados en GPT.

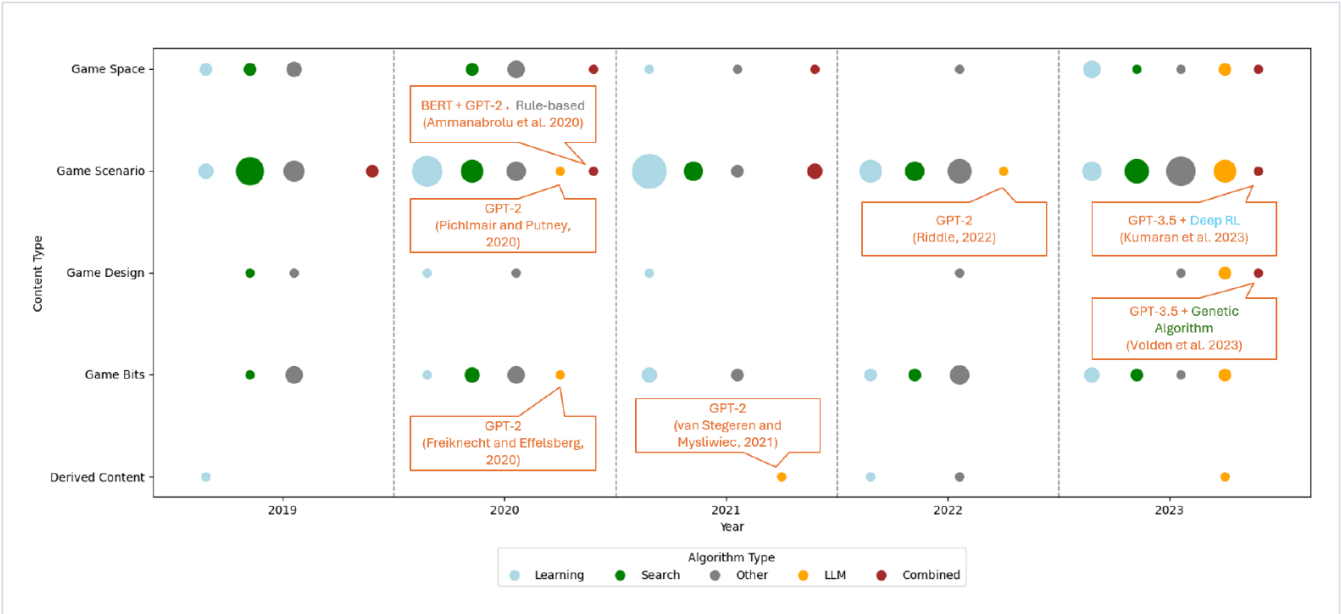


Figura 2. Línea de tiempo de la investigación publicada entre 2019 y 2023 en las conferencias seleccionadas, ordenada por tipo de contenido. Se destacan algunos trabajos con LLM.



Figura 3. Nube de palabras con los autores de los artículos revisados; el tamaño es proporcional al número de artículos en coautoría.

Vacíos en la investigación

- **Generación de niveles 3D:** poco estudiada pese a que los juegos 3D dominan la industria.
- **Falta de continuidad:** muchas ideas innovadoras no se desarrollan después (excepción: *1001 Nights*). Los autores proponen crear demos jugables para atraer inversión y acortar la brecha con la industria.
- **Ética:** el uso de LLM para generar contenido plantea consideraciones éticas.

Posibles direcciones de investigación

- Los **métodos combinados**, sobre todo aprendizaje profundo con LLM, serán un tema popular.
- En vez de generar niveles completos, enfocarse en **reparar** contenido incorrecto, reduciendo el esfuerzo para obtener un producto terminado.
- Explorar los LLM como asistentes de diseño, generadores de historias y misiones, e incluso **generadores de niveles** que producen niveles como secuencias de palabras; especialmente alternativas abiertas a los modelos comerciales.

Conclusión

El survey clasifica los algoritmos de PCG en cinco grupos (búsqueda, aprendizaje automático, otros, LLM y combinados), analiza artículos de 2019–2023 e identifica tendencias, vacíos y direcciones futuras. El uso de LLM para tareas generativas es un desarrollo reciente, y la combinación de aprendizaje profundo (GAN, RL) con otros algoritmos gana cada vez más atención; ambas tendencias se apoyan en los avances del aprendizaje profundo. Los autores recomiendan profundizar en cada subcategoría de contenido, investigar qué algoritmos se ajustan mejor a cada tipo de contenido y dedicar un estudio a los **algoritmos de evaluación** del contenido generado.

Utilidad para tu investigación (plataformas 2D)

- **Estado del arte y tendencia actual:** da la clasificación de métodos y los datos para justificar el tema (102 de 207 artículos son de niveles; Mario aparece en 18).
- **Limitación a tener en cuenta:** no es específico de plataformas ni revisa trabajos anteriores a 2019 salvo excepciones; por eso Launchpad (2011) no figura en su muestra.
- **Matiz discutible:** clasifica WFC como método de búsqueda, mientras que Karth y Smith (2017) lo describen como resolución de restricciones.
- **Observación útil para tu modelo:** las GAN tratan los niveles como imágenes y no consideran restricciones de validez, lo que motiva modelos con restricciones explícitas de jugabilidad.